

Házi feladat

Üzleti Intelligencia Laboratórium

Félév: 2026 tavasz

Movie Analytics Platform

Rába Tamás - CRLJQ8

tomi.dani15@gmail.com

Bemutató

A Movie Analytics Platform egy teljes körű üzleti intelligencia rendszer, amely a filmipar adatainak elemzésére, prediktív modellezésére és vizualizációjára szolgál. A rendszer Azure cloud infrastruktúrára épült, Apache Airflow orkesztrációval ütemezett ETL pipeline-nal, dbt transzformációs réteggel, Power BI dashboardokkal és gépi tanulási modellekkel.

Két adatforrásból dolgozik: a Kaggle TMDb Movies Dataset (~45 ezer film, CSV formátum, 4 részletben betöltve) és a TMDb REST API (valós idejű JSON frissítések). Az adatok egy Azure Blob Storage Raw rétegbe kerülnek, majd Python ETL scriptek és dbt transzformációk segítségével egy Azure SQL Data Warehouse csillag sémájába töltődnek be. Az egész pipeline Apache Airflow-val van ütemezve, Docker Compose környezetben.

Az adatelemzési rész két fő komponensből áll: egy Linear Regression modellből ($R^2=0.70$, bevétel-predikció budget/műfaj/stúdió alapján, scikit-learn) és egy új idősoros előrejelzésből Prophet könyvtárral, amely az éves filmipari bevételi trendeket jelzi előre 2025–2029-re.


Főbb eredmények

- 10,834 film feldolgozva – Kaggle CSV (4 chunk) + TMDb API delta load
- Data Warehouse: 9 tábla (Star Schema) – 4 Dim + Fact + 2 Agg + Staging + ETL_Log
- Data Quality: 0.10% invalid records (EXCELLENT) – 19 validációs szabály, 35,885 rekord
- ML Model: Linear Regression, $R^2=0.70$, CV Mean $R^2=0.70$ (Kfold shuffle=True, 5-fold)
- Prophet idősor: éves filmipari bevételi trend előrejelzés 2025–2029
- Power BI: 4 interaktív dashboard - Vezető döntéshozói, műfaj elemzési, jövedelmezőségi és ML predikciós dashboardok, amelyek valós idejű üzleti betekintést nyújtanak interaktív vizualizációkkal.
- ETL Orchestration: Apache Airflow DAG (8 task, napi 02:00 ütemezés, idempotens)
- dbt transzformációs réteg: 4 modell, 11/11 teszt PASSED
- Testing: 28/28 Pytest passed, 100% coverage

ARCHITEKTÚRA + INFRASTRUKTÚRA

RENDSZER ARCHITEKTÚRA

Adatfolyam: A rendszer két fő adatforrást integrál: a Kaggle TMDb adathalmazt (10,834 film, 4 CSV chunk) és a TMDb REST API-t (delta load). Mindkét forrás adatai először az Azure Blob Storage Raw layerébe kerülnek nyers CSV és JSON formátumban. Ezt követően az Apache Airflow DAG-ban futó Python ETL scriptek dolgozzák fel az adatokat: először egy Staging táblába, majd dbt modelleken keresztül a Data Warehouse csillag sémába (4 dimenzió + 1 fact tábla) töltődnek be. A végeredmény: Power BI interaktív dashboardok, Machine Learning predikciós modell, Prophet idősoros előrejelzés és automatizált data quality validation.



A rendszer architektúrája

AZURE INFRASTRUKTÚRA

Létrehozott Resources:

1. **Azure SQL Database** (movie_analytics_db) - Standard S2 (50 DTU), France Central, movie-analytics-server-rtamas
2. **Azure Blob Storage** (movieanalyticsstore) - Raw layer CSV/JSON, Hot tier, 90 nap retention
3. **Apache Airflow** - Docker Compose, 3 container (webserver, scheduler, postgres)
4. **Azure Container Web App** (movieanalytics-webapp) - Docker deployment, Python 3.12, 6 HTTP ETL endpoints, korábbi BI tárgy ETL endpoint (meglévő)

DATA WAREHOUSE SÉMA

Star Schema - 9 tábla:

- Staging: Staging_Movies (10,834 rekord – 4 CSV chunk alapján)
- Dimensions: Dim_Genre (20), Dim_Time (40,359), Dim_Studio (10,284), Dim_Country (70)
- Fact: Fact_Movies (25,051 rekord – multi-genre design)
- Aggregations: Agg_Genre_Performance, Agg_Yearly_Trends
- Audit: ETL_Log (job tracking)
- dbt nézetek: stg_movies (view), dim_genre, fact_movies, agg_by_genre (table)

ETL FOLYAMAT + IMPLEMENTÁCIÓ

ETL PIPELINE (6 Python ETL Script):

1. etl_csv_chunk_to_staging.py - Kaggle CSV chunk-alapú betöltés → Staging (10,834 film, 4 × ~2,708 sor), NULL handling, date formatting, idempotens UPSERT logika (source mező ellenőrzés)

2. `etl_api_refresh.py` - TMDb API → 520 film lekérdezés, delta load (11 új film), 3.5 perc, rate limiting 250ms
3. `etl_load_dimensions.py` - Staging → 4 Dim tábla, surrogate key generálás, SCD Type 1
4. `etl_load_fact.py` - Staging+Dim → Fact (25,051 rekord), FK feloldás, profit/ROI számítás
5. `etl_load_aggregations.py` - Fact → Agg táblák, műfaj/év aggregációk, 10x gyorsabb dashboard
6. `etl_data_quality_validation.py` - 19 validáció, 35,885 rekord, 35 invalid (0.10%)

APACHE AIRFLOW DAG (8 task, napi 02:00)

Az előző félévben az ETL job-okat Azure Container Web App HTTP API endpoint-okon keresztül triggereltem. Ezt az megközelítést váltotta fel az Apache Airflow DAG-alapú orkesztráció.

Az összes ETL job Apache Airflow DAG-ban fut, napi ütemezéssel (02:00), Docker Compose környezetben. A DAG idempotens – UPSERT logika és source mező ellenőrzés alapján minden task újrafuttatható duplikáció nélkül.

- `ingest_csv_chunk_1` – Kaggle CSV 1. részlet (2,708 film) → Azure Blob Raw réteg
- `ingest_csv_chunk_2` – Kaggle CSV 2. részlet (2,708 film) → Azure Blob Raw réteg
- `ingest_csv_chunk_3` – Kaggle CSV 3. részlet (2,708 film) → Azure Blob Raw réteg
- `ingest_csv_chunk_4` – Kaggle CSV 4. részlet (2,710 film) → Azure Blob Raw réteg
- `load_dimensions` – Staging → Dim táblák (surrogate key, SCD Type 1)
- `load_fact` – Staging + Dim → Fact_Movies (FK feloldás, profit/ROI számítás)
- `load_aggregations` – Fact → Agg táblák (műfaj/év aggregációk)
- `data_quality_validation` – 19 validációs szabály, hibák logolása ETL_Log-ba

CSV CHUNK-ALAPÚ BETÖLTÉS (Idempotencia)

A Kaggle CSV fájl (~45 ezer sor) 4 egyenlő részre van osztva (`movies_chunk_1–4.csv`, ~2,708 film/chunk). Az ETL job minden futtatáskor ellenőrzi a source mezőt a `Staging_Movies` táblában: ha az adott chunk már be van töltve (`source = 'CSV_chunk_1' ... 'CSV_chunk_4'`), kihagyja az újrabetöltést. Ez teszi lehetővé a változás demonstrálását az ETL újrafuttatásával: az első futáskor csak `chunk_1` töltődik be, majd a következő futáskor `chunk_2`, stb.

DBT TRANSZFORMÁCIÓS RÉTEG

A dbt (data build tool) réteg SQL-alapú modellek segítségével végzi el a Staging → DWH transzformációt:

- `stg_movies` (view) – Tisztított staging adatok (NULL szűrés, budget/revenue > 0 filter)
- `dim_genre` (table) – Műfaj dimenzió, unique + not_null tesztek
- `fact_movies` (table) – Ténytábla JOIN-okkal (Staging + Dim táblák, profit/ROI számítás)
- `agg_by_genre` (table) – Műfajonkénti aggregációk (total films, revenue, avg ROI)

dbt tesztek: 11/11 PASSED – NOT NULL, unique, referential integrity minden modellre. A columnstore indexek le vannak tiltva (Azure SQL Basic tier korlát).

TESZTELÉS (Pytest -28/28 PASSED):

`test_csv_parsing.py` (10) - CSV struktúra, data types, oszlopok, min. 1000 sor

`test_null_handling.py` (7) - NULL %, kritikus mezők, profit/ROI kalkuláció

`test_data_quality.py` (7) - Negatív értékek, rating 0-10, referenciális integritás, **0.10% invalid < 0.5%**

`test_integration.py` (4) - End-to-end flow, 100 sample tracking

Validation Results: 35,885 rekord ellenőrizve, 35 invalid (0.10%), EXCELLENT minősítés

Email Alerting: SMTP (Gmail), failure notifications, HTML error details

POWER BI + MACHINE LEARNING

POWER BI DASHBOARDS (4 DB)

1. Executive Dashboard - Vezető döntéshozói áttekintés

Ez a dashboard a legfelsőbb szintű üzleti metrikákat jeleníti meg. A négy KPI kártya (\$1.98B összbevétel, 25 ezer film, \$1.28B összprofit, 6.3 átlagos értékelés) azonnal látható számokat mutat, lehetővé téve a vezetők számára a főbb trendek gyors megértését. Az éves bevételi trend vonaldiagram tisztán mutatja, hogy a filmipar bevételei **exponenciálisan növekedtek az 1980-as évektől**, különösen látványos a növekedés a 2000-es évek elején a blockbuster filmek és franchise-ok térnyerésével (Marvel, Avatar). A bevétel megoszlása műfaj szerint pie chart mutatja, hogy az **Action (14.48%) és Adventure (14.35%) dominálják a piacot**, de a Comedy (11.45%), Drama (10.15%) és Science Fiction (7.56%) is jelentős részesedéssel bírnak. A Top 10 legnagyobb bevételű film bar chart azonnal feltárja, hogy **Avatar (\$2.8B), Avengers: Endgame (\$2.8B) és The Lion King vezetnek** a listát. A Top 10 stúdió táblázat szerint **Warner Bros (\$97.7B), Disney (\$142.9B) és Universal (\$126.1B)** a legnagyobb bevételű stúdiók. Az interaktív szűrők (év, műfaj, stúdió) lehetővé teszik a drill-down elemzést.

Fő felismerések: A bevételek **exponenciálisan növekedtek** az 1900-as évektől a 2020-as évekig, különösen a 2000-es évektől. A legnagyobb bevételű filmek jellemzően **Action/Adventure franchise-ok** (Avatar, Avengers, Star Wars). Az átlagos értékelés **6.3/10**, amely mérsékelt minőséget jelez. A **legsikeresebb stúdiók diverzifikáltak** (Warner Bros, Disney, Universal), míg a specializált stúdiók (Pixar, DreamWorks) is jelentős bevétellel rendelkeznek.

2. Genre Analysis - Műfaji elemzés részletesen

Ez a dashboard a filmműfajok mély elemzésére fókuszál. Az **Action műfaj vezet \$286.55 milliárd bevétellel és 2,526 ezer filmmel**, ami messze meghaladja a többi műfajt. A Genre Performance Metrics táblázat részletes összehasonlítást ad: a **Horror műfaj (Avg ROI: 13.44) a legjövedelmezőbb**, míg a Documentary (ROI: 9.15) és Mystery (ROI: 9.50) is kiváló megtérülést mutat. A Budget vs Revenue scatter plot azonnal láthatóvá teszi, hogy **Action és Adventure műfajok (nagy kék körök jobb felül) magas költségvetéssel és magas bevétellel** rendelkeznek, míg a **Comedy, Family és Animation (közép) mérsékelt költségvetéssel mérsékelt bevételt** érnek el. A Horror, Documentary és Romance műfajok (bal alsó sarokban kis körök) **alacsony költségvetéssel alacsony abszolút bevételt**, de **magas ROI-t** érnek el. A műfajok bevétele évtizedenként bar chart mutatja, hogy a **2000-es évektől az Action/Adventure dominancia erősödött**, míg a klasszikus műfajok (Western, Musical) szinte eltűntek.

Fő felismerések: Az **Action/Adventure dominálja** a piacot mind bevételben (együtt ~\$570B), mind filmszámban. A **Horror (ROI: 13.44) és Mystery (ROI: 9.50) a legjövedelmezőbbek**, mivel alacsony költségvetéssel készülnek de vonzó niche közönséget céloznak. A **Drama műfajból készül sok film** (5674 összesen), de átlagos bevételük alacsonyabb. A **sci-fi, fantasy és superhero filmek növekvő tendenciát** mutatnak a 2000-es évektől a franchise-ok térnyerésével.

3. Profitability & ROI Analysis - Jövedelmezőségi elemzés

Ez a dashboard a filmek pénzügyi teljesítményére koncentrál. A négy KPI kártya mutatja: **\$1.28B összprofit, \$50.94M átlagos profit filmenként, 64.49% profit margin** (amely kiváló jövedelmezőséget jelez), és **17 ezer profitábilis film**. A Studio-Genre Profit Matrix táblázat részletesen lebontja, hogy **mely stúdiók mely műfajokban érnek el profitot**: például **Marvel Studios \$24.3B-t az Action-ben, Pixar \$8.4B-t az Animation-ben, Columbia Pictures \$10B-t az Action-ben**. A Profit Breakdown by Genre area chart mutatja, hogy a **profit folyamatosan növekedett az 1920-as évektől**, különösen meredek emelkedés látható a 2000-es évektől. A **Top 10 Highest ROI filmek** (Love 911, Between Us, Kiss of the Spider Woman, stb.) jellemzően **kis költségvetésű független vagy horror filmek**, amelyek kimagasló megtérülést értek el. A **Bottom 10 Lowest ROI filmek** (The 312, Gold, Delgo, A Family On Edge, stb.) jellemzően **nagy költségvetésű bukások**, amelyek nem találták meg a közönségüket. Az **ROI Distribution histogram** mutatja, hogy a **legtöbb film 0-10x ROI tartományban van**, csak kevés film éri el a 50x+ ROI-t.

Fő felismerések: A **legtöbb film mérsékelt profitot** ér el (0-3x ROI), amely stabil, de nem kiemelkedő megtérülést jelent. A **legnagyobb nyereségű filmek franchise-ok** (Marvel, Pixar), amelyek ismétlődő bevételi forrást jelentenek. A **legnagyobb veszteségek high-budget filmek**, amelyek alulteljesítettek (Delgo, A Family On Edge). A **stúdiók specializálódnak: Marvel az Action-ben, Pixar az Animation-ben**, míg a **nagy stúdiók (Warner Bros, Universal) diverzifikáltak** több műfajban. Az **átlagos profit margin 64.49%**, amely egészséges profitabilitást jelez az iparágban.

4. ML Predictions Dashboard - Gépi tanulási előrejelzések

Ez a dashboard a Linear Regression modell eredményeit vizualizálja. A három KPI kártya mutatja: **Model Accuracy (R²): 0.7005** (amely meghaladja a specifikációban előírt 0.6-os küszöböt), **Mean Absolute Error (MAE): \$38.44M** (a modell átlagosan ±38.44 millió dollárral tér el a valós bevételtől), és **11 ezer total predictions** (előrejelzés a teljes test set-re).

Az **Actual vs Predicted Revenue scatter plot** mutatja, hogy a modell előrejelzései mennyire közelítik a valós bevételeket - a **zöld pontok (over-performing filmek)** a **trendline felett**, a **piros pontok (under-performing filmek)** a **trendline alatt** helyezkednek el. A legtöbb pont közel van a diagonális trendline-hoz, ami jó modell fit-et jelez.

A **Top 10 Over-Performing Films** táblázat kiemeli azokat a filmeket, amelyek **jelentősen jobban teljesítettek** az előrejelzésnél: **Avatar (\$2.92B actual vs \$1.16B predicted, +\$1.76B error)**, **Avatar: The Way of Water (\$2.32B vs \$1.10B, +\$1.22B)**, **Avengers: Endgame (\$2.80B vs \$1.23B, +\$1.57B)**, **Barbie (\$1.45B vs \$481M, +\$965M)**. Ezek jellemzően **blockbuster franchise filmek**, amelyek viral marketing, word-of-mouth és brand értékük miatt meghaladják a költségvetés-alapú előrejelzéseket.

A **Top 10 Under-Performing Films** táblázat kiemeli azokat a filmeket, amelyek **rosszabbul teljesítettek**: **DeAD (\$201M actual vs \$942M predicted, -\$740M error)**, **Fight Club (\$101M vs \$824M, -\$724M)**, **Interstellar (\$702M vs \$1.16B, -\$461M)**, **Pulp Fiction (\$214M vs \$675M, -\$461M)**. Ezek gyakran **kultikus vagy art house filmek**, amelyek kisebb közönséget céloznak meg, vagy nem találták meg a mainstream piacot a kiadáskor.

A **Prediction Performance Distribution** bar chart mutatja, hogy **~6 ezer film over-performed** (zöld), míg **~2 ezer film under-performed** (piros). Ez azt jelenti, hogy a modell **konzervatív előrejelzéseket** ad, gyakrabban alulbecsülve a filmek bevételét.

Fő felismerések: A modell **70.05%-os pontossággal ($R^2=0.7005$)** jósolja a bevételeket, amely megbízható üzleti döntéshozatalhoz. Az **átlagos hiba \$38.44M**, amely elfogadható margin a film ipar volatilitását figyelembe véve. A **budget a legerősebb prediktor** - magasabb budget általában magasabb bevételt eredményez. Azonban vannak kivételek: **blockbuster franchise filmek gyakran felüteljesítenek** (Avatar, Avengers, Barbie), mivel a brand érték, marketing és word-of-mouth hatások nehezen modellezhetők. **Art house és kultikus filmek gyakran alulteljesítenek** (Fight Club, Pulp Fiction, The Shawshank Redemption), mivel kisebb niche közönséget céloznak meg. A modell **konzervatív**, hiszen több film teljesít jobban mint várva (6e vs 2e), amely biztonságos megközelítés a befektetési döntéseknél.

MACHINE LEARNING MODEL

Linear Regression - Revenue Prediction

Features (bemeneti változók):

- **Budget (numeric)** - A film költségvetése dollárban, amely a legerősebb prediktor a bevétel előrejelzésében. Standardizálva van 0 átlag és 1 szórásra a jobb modell teljesítményért.
- **Genre (one-hot encoded)** - A műfaj kategórikus változó, amely 20 dummy változóra lett széttranszformálva (is_Action, is_Horror, stb.). Például egy Action film esetén is_Action=1, összes többi műfaj=0.
- **Release Month (categorical)** - A megjelenési hónap (1-12), amely szezonálisitást rögzít - például a nyári hónapok (június-augusztus) magasabb bevétellel járnak.
- **Studio (one-hot encoded)** - A stúdió neve one-hot encoding-gal kódolva, amely rögzíti a nagy stúdiók brand értékét (pl. Disney filmek várhatóan magasabb bevételt érnek el).

Model Performance (teljesítmény metrikák):

- **R^2 Score: 0.7005** - A modell a bevétel variációjának 70%-át magyarázza, amely meghaladja a specifikációban előírt 0.6-os küszöböt. Ez azt jelenti, hogy a modell megbízhatóan előre tudja jelezni a legtöbb film bevételét.
- **Mean Absolute Error (MAE): \$38.44M** - A modell átlagosan ± 38.44 millió dollárral tér el a valós bevételtől.
- **Train/Test Split: 80/20** - A teljes adathalmaz 80%-át használtam a modell tanítására (8,667 film) és 20%-át tesztelésre (2,167 film), amely biztosítja hogy a modell nem overfitted.
- **Cross-Validation: 5-fold** - Az adathalmazt 5 részre osztottam és 5-ször tanítottam a modellt, minden alkalommal más részt hagyva ki validációra. Ez biztosítja a robusztus teljesítmény becslést.
- **Mean CV Score: 0.70** - Az 5 cross-validation fold átlagos R^2 értéke 0.70 (KFold shuffle=True, random_state=42), amely konzisztens a test score-ral (0.70), tehát a modell nem overfitted.

Predictions (előrejelzések):

- **Output:** revenue_predictions.csv - A modell kimenete egy CSV fájl, amely minden test filmre (11,000 film) tartalmazza az actual és predicted bevételt.
- **Columns:** actual_revenue (valós bevétel), predicted_revenue (előrejelzett bevétel), error (eltérés a kettő között), film_title (film címe az azonosításhoz).
- **Power BI import successful** - A CSV sikeresen importálva lett a Power BI-ba, amely lehetővé teszi az interaktív vizualizációt és performance analysis-t.

Key Insights from ML (főbb felismerések):

- **Budget → Revenue correlation: 0.75** - Erős pozitív korreláció a költségvetés és bevétel között, amely azt mutatja hogy a magasabb költségvetés általában magasabb bevételt eredményez, de nem garantáltan.
- **Top predictive features: Budget, Genre (Action/Adventure)** - A modell feature importance analízise szerint a budget a legerősebb prediktor, majd az Action/Adventure műfaj, amely szignifikánsan növeli a várható bevételt.
- **Over-performing films: Blockbuster franchises** - Avatar (+\$1.76B), Avengers: Endgame (+\$1.57B), Barbie (+\$965M) jelentősen meghaladták a költségvetés-alapú előrejelzéseket a brand érték és viral marketing miatt.
- **Under-performing films: Art house/kultikus filmek** - Fight Club (-\$724M), Pulp Fiction (-\$461M), The Shawshank Redemption (-\$582M) kisebb közönséget céloztak meg, mint a mainstream blockbusterek.
- **Konzervatív modell:** ~6000 film over-performed vs ~2000 under-performed, amely azt mutatja hogy a modell biztonságos (alulbecsüli a bevételeket), amely jó befektetési döntéshozatalhoz.

Data Model: A Power BI data modellje a Data Warehouse star sémáját tükrözi, DirectQuery módban az SQL Database felé a valós idejű adatokért, és Import módban az aggregált táblák esetén a gyorsabb betöltésért. A DAX mértékek kiszámítják a komplex metrikákat: Total Revenue összegzi a fact tábla összes bevételét, Avg ROI átlagolja a megtérülési rátákat, Profit Margin kiszámítja a profit és bevétel arányát százalékban. Ezek a mértékek dinamikusan újraszámolódnak amikor a felhasználó szűrőket alkalmaz.

Idősoros előrejelzés - PROPHET

A Prophet könyvtárral (Meta) éves filmipari bevételi trend előrejelzést készítettem 2025–2029-re. A modell az Agg_Yearly_Trends tábla 1980–2024 közötti éves aggregált bevételi adataira tanult.

Módszertan:

- Bemenet: Agg_Yearly_Trends tábla – éves total_revenue aggregáció (1980–2024, 45 adatpont)
- changepoint_prior_scale=0.3, interval_width=0.95 (95%-os konfidencia intervallum)
- Kimenet: prophet_forecast.csv + prophet_forecast.png vizualizáció

Előrejelzési eredmények (Prophet):

- 2025: \$28.82B (95% CI: \$7.76B – \$47.66B)
- 2026: \$23.53B (95% CI: \$2.79B – \$43.46B)
- 2027: \$18.24B (95% CI: -\$0.57B – \$37.99B)
- 2028: \$12.94B (95% CI: -\$6.96B – \$33.21B)
- 2029: \$7.65B (95% CI: -\$13.20B – \$27.63B)

Megjegyzés: A csökkenő trend a COVID-19 járvány 2020-as hatását tükrözi (\$17.74B bevétel, szemben a 2019-es \$92.77B-vel). A modell ezt a törést trendváltásként értelmezi. A széles konfidencia intervallum a filmipar volatilitásából adódik. Az előrejelzési grafikon a data/processed/prophet_forecast.png fájlban érhető el.

Összegzés

A Movie Analytics Platform egy production-ready üzleti intelligencia rendszer, amely modern cloud-native megközelítést alkalmaz.

A projekt az Üzleti Intelligencia tárgyból (2025 ősz, megajánlott 5) teljesített Movie Analytics Platform kiterjesztett verziója, amelyet az Üzleti Intelligencia Laboratórium tárgy követelményeinek megfelelően bővítettem.

Új komponensek (2026 tavasz):

- Apache Airflow DAG orchestration (8 task, napi ütemezés, idempotens UPSERT logika)
- dbt transzformációs réteg (4 modell, 11 teszt, automatikus dokumentáció)
- CSV chunk-alapú betöltés (4 részlet, ETL változás demonstrálható)
- Prophet idősoros előrejelzés (2025–2029, 95% CI)
- ML modell javítása (KFold shuffle=True, CV Mean $R^2=0.70$, stabil eredmény)

A rendszer valós üzleti értéket teremt a filmipar számára, prediktív modellezéssel és interaktív dashboardokkal támogatva a döntéshozatalt. A projekt során azonosított üzleti insights (műfaji trendek, költségvetés-bevétel összefüggés, stúdió teljesítmény) konkrét stratégiai döntéseket támogatnak: mely műfajokba érdemes befektetni, mekkora költségvetéssel maximalizálható az ROI, mely stúdiókkal érdemes partnerséget kötni. GitHub Repository: [RabaTamas/MovieAnalyticsPlatform](https://github.com/RabaTamas/MovieAnalyticsPlatform)

Videó: https://drive.google.com/file/d/1a3eSnndrM2cBj67vN5HIWZ-L8uhkbRJ6/view?usp=drive_link