

Házi feladat specifikáció

Üzleti Intelligencia

Félév: 2025 őszi

Movie Analytics Platform

Rába Tamás - CRLJQ8

tomi.dani15@gmail.com

Bemutató

A Movie Analytics Platform egy teljes körű üzleti intelligencia rendszer, amely a filmipar adatainak elemzésére, prediktív modellezésére és vizualizációjára szolgál. A rendszer Azure cloud infrastruktúrára épült, Docker containerizált ETL folyamatokkal, Power BI dashboardokkal és gépi tanulási modellel.

Főbb eredmények

- 11,177 film feldolgozva - A Kaggle CSV adathalmazból 10,834 film került betöltésre, amelyet a TMDB API-ból további 343 filmmel egészítettünk ki a naprakész adatok biztosítása érdekében.
- Data Warehouse: 9 tábla (Star Schema) - Optimalizált csillag séma architektúrával, amely egy központi fact táblát, négy dimension táblát, két aggregált táblát, egy staging és egy audit táblát tartalmaz a gyors lekérdezések és rugalmas elemzések támogatására.
- Data Quality: 0.12% invalid records (EXCELLENT) - A 19 különböző validációs teszt alapján az adatok minősége kiemelkedő, jelentősen alulmúlva a specifikációban előírt 0.5%-os hibaarány küszöböt.
- ML Model: Linear Regression, $R^2 = 0.70$ - A gépi tanulási modell 70%-os pontossággal képes előre jelezni a filmek bevételeit a költségvetés, műfaj és egyéb paraméterek alapján, amely meghaladja a specifikációban előírt 0.6-os R^2 küszöböt.
- Power BI: 4 interaktív dashboard - Vezető döntéshozói, műfaj elemzési, jövedelmezőségi és ML predikciós dashboardok, amelyek valós idejű üzleti betekintést nyújtanak interaktív vizualizációkkal.
- ETL Automation: Azure Container Web App, 6 HTTP endpoint - Docker containerizált Python ETL script-ek, amelyek HTTP API-n keresztül triggerelhetők, lehetővé téve a rugalmas és skálázható adatfeldolgozást.
- Testing: 28/28 Pytest passed, 100% coverage - Teljes körű unit és integrációs tesztek, amelyek validálják a CSV parsing, NULL handling, data quality és end-to-end adatfolyam helyességét.


Implementációs megközelítés

Az eredeti specifikáció Azure Data Factory pipeline orchestration-t írt elő. Az implementáció során alternatív megoldást választottam: **Azure Container Web App Docker deployment**, amely HTTP-triggered ETL job-okat biztosít. Ez rugalmasabb, skálázhatóbb és költséghatékonyabb, mivel API-driven orchestration-t, egyszerűbb debugging-ot és pay-per-execution költségmodellt tesz lehetővé.

ARCHITEKTÚRA + INFRASTRUKTÚRA

RENDSZER ARCHITEKTÚRA

Adatfolyam: A rendszer két fő adatforrást integrál: a Kaggle TMDB adathalmazt (10,834 film) és a TMDB REST API-t (343 új film). Mindkét forrás adatai először az Azure Blob Storage Raw layerébe kerülnek nyers CSV és JSON formátumban. Ezt követően az Azure Container Web App Docker containerben futó Python ETL script-ek dolgozzák fel az adatokat, amelyek először egy Staging táblába, majd a Data Warehouse csillag sémába (4 dimenzió + 1 fact tábla) töltődnek be. A végeredmény három fő komponens: Power BI interaktív dashboardok, Machine Learning predikciós modell és automatizált data quality validation.



A rendszer architektúrája

AZURE INFRASTRUKTÚRA

Létrehozott Resources:

1. **Azure SQL Database** (movie_analytics_db) - Standard S2 (50 DTU), France Central, movie-analytics-server-rtamas
2. **Azure Blob Storage** (movieanalyticsstore) - Raw layer CSV/JSON, Hot tier, 90 nap retention
3. **Azure Container Registry** (movieanalyticsregistry) - Docker image repository, movieanalytics-func:latest
4. **Azure Container Web App** (movieanalytics-webapp) - Docker deployment, Python 3.12, 6 HTTP ETL endpoints
5. **Azure Data Factory** (movieanalytics-adf-rtamas) - Infrastruktúra létrehozva, Linked Services (SQL + Blob), pipeline pending

DATA WAREHOUSE SÉMA

Star Schema - 9 tábla:

Staging: Staging_Movies (11,177 rekord)

Dimensions: Dim_Genre (19), Dim_Time (111 év), Dim_Studio (1,600+), Dim_Country (141)

Fact: Fact_Movies (25,051 rekord - multi-genre design)

Aggregations: Agg_Movies_By_Genre, Agg_Movies_By_Year

Audit: ETL_Log (job tracking)

ETL FOLYAMAT + IMPLEMENTÁCIÓ

ETL PIPELINE (6 Python ETL Script):

1. etl_csv_to_staging.py - Kaggle CSV → Staging (10,834 film), NULL handling, date formatting
2. etl_api_refresh.py - TMDB API → 520 film lekérdezés, delta load (11 új film), 3.5 perc, rate limiting 250ms
3. etl_load_dimensions.py - Staging → 4 Dim tábla, surrogate key generálás, SCD Type 1
4. etl_load_fact.py - Staging+Dim → Fact (25,051 rekord), FK feloldás, profit/ROI számítás
5. etl_load_aggregations.py - Fact → Agg táblák, műfaj/év aggregációk, 10x gyorsabb dashboard
6. etl_data_quality_validation.py - 19 validáció, 36,368 rekord, 44 invalid (0.12%), 1.7 sec

AZURE CONTAINER WEB APP DEPLOYMENT

Docker Process: Dockerfile (Python 3.12, ODBC Driver 17) → requirements.txt (pandas, pyodbc, sqlalchemy) → Docker build → Tag → Push (ACR) → Web App pull → Automatic deployment

HTTP API Endpoints (6 db):

- validation - Data quality check (19 szabály)

- api_refresh - TMDb API delta load
- csv_import, dimensions, fact, aggregations - Setup/refresh job-ok

Base URL: <https://movieanalytics-webapp-prt-ccgsgpdxckb7g0h5.francecentral-01.azurewebsites.net>

TESZTELÉS (Pytest -28/28 PASSED):

test_csv_parsing.py (10) - CSV struktúra, data types, oszlopok, min. 1000 sor

test_null_handling.py (7) - NULL %, kritikus mezők, profit/ROI kalkuláció

test_data_quality.py (7) - Negatív értékek, rating 0-10, referenciális integritás, **0.12% invalid < 0.5%**

test_integration.py (4) - End-to-end flow, 100 sample tracking

Validation Results: 36,368 rekord ellenőrizve, 44 invalid (0.12%), **EXCELLENT** minőség

Email Alerting: SMTP (Gmail), failure notifications, HTML error details

POWER BI + MACHINE LEARNING

POWER BI DASHBOARDS (4 DB)

1. Executive Dashboard - Vezető döntéshozói áttekintés

Ez a dashboard a legfelsőbb szintű üzleti metrikákat jeleníti meg. A négy KPI kártya (\$1.98B összbevétel, 25 ezer film, \$1.28B összprofit, 6.3 átlagos értékelés) azonnal látható számokat mutat, lehetővé téve a vezetők számára a főbb trendek gyors megértését. Az éves bevételi trend vonaldiagram tisztán mutatja, hogy a filmipar bevételei **exponenciálisan növekedtek az 1980-as évektől**, különösen látványos a növekedés a 2000-es évek elején a blockbuster filmek és franchise-ok térnyerésével (Marvel, Avatar). A bevétel megoszlása műfaj szerint pie chart mutatja, hogy az **Action (14.48%) és Adventure (14.35%) dominálják** a piacot, de a Comedy (11.45%), Drama (10.15%) és Science Fiction (7.56%) is jelentős részesedéssel bírnak. A Top 10 legnagyobb bevételű film bar chart azonnal feltárja, hogy **Avatar (\$2.8B), Avengers: Endgame (\$2.8B) és The Lion King vezetnek** a listát. A Top 10 stúdió táblázat szerint **Warner Bros (\$97.7B), Disney (\$142.9B) és Universal (\$126.1B)** a legnagyobb bevételű stúdiók. Az interaktív szűrők (év, műfaj, stúdió) lehetővé teszik a drill-down elemzést.

Fő felismerések: A bevételek **exponenciálisan növekedtek** az 1900-as évektől a 2020-as évekig, különösen a 2000-es évektől. A legnagyobb bevételű filmek jellemzően **Action/Adventure franchise-ok** (Avatar, Avengers, Star Wars). Az átlagos értékelés **6.3/10**, amely mérsékelt minőséget jelez. A **legsikeresebb stúdiók diverzifikáltak** (Warner Bros, Disney, Universal), míg a specializált stúdiók (Pixar, DreamWorks) is jelentős bevétellel rendelkeznek.

2. Genre Analysis - Műfaji elemzés részletesen

Ez a dashboard a filmműfajok mély elemzésére fókuszál. Az **Action műfaj vezet \$286.55 milliárd bevétellel és 2,526 ezer filmmel**, ami messze meghaladja a többi műfajt. A Genre Performance Metrics táblázat részletes összehasonlítást ad: a **Horror műfaj (Avg ROI: 13.44) a legjövedelmezőbb**, míg a Documentary (ROI: 9.15) és Mystery (ROI: 9.50) is kiváló megtérülést mutat. A Budget vs Revenue scatter plot azonnal láthatóvá teszi, hogy **Action és Adventure műfajok (nagy kék körök jobb felül) magas költségvetéssel és magas bevétellel rendelkeznek**, míg a **Comedy, Family és Animation (közép) mérsékelt költségvetéssel mérsékelt bevételt érnek el**. A Horror, Documentary és Romance műfajok (bal alsó sarkban kis körök) **alacsony költségvetéssel alacsony abszolút bevételt, de magas ROI-t érnek el**. A műfajok bevétele évtizedenként bar chart mutatja, hogy a **2000-es évektől az Action/Adventure dominancia erősödött**, míg a klasszikus műfajok (Western, Musical) szinte eltűntek.

Fő felismerések: Az **Action/Adventure dominálja** a piacot mind bevételben (együtt ~\$570B), mind filmszámban. A **Horror (ROI: 13.44) és Mystery (ROI: 9.50) a legjövedelmezőbbek**, mivel alacsony költségvetéssel készülnek de vonzó niche közönséget céloznak. A **Drama műfajból készül sok film** (5674 összesen), de átlagos bevételük alacsonyabb. A **sci-fi, fantasy és superhero filmek növekvő tendenciát mutatnak** a 2000-es évektől a franchise-ok térnyerésével.

3. Profitability & ROI Analysis - Jövedelmezőségi elemzés

Ez a dashboard a filmek pénzügyi teljesítményére koncentrál. A négy KPI kártya mutatja: **\$1.28B összprofit, \$50.94M átlagos profit filmenként, 64.49% profit margin** (amely kiváló jövedelmezőséget jelez), és **17 ezer profitábilis film**. A Studio-Genre Profit Matrix táblázat részletesen lebontja, hogy **mely stúdiók mely műfajokban érnek el profitot**: például **Marvel Studios \$24.3B-t az Action-ben, Pixar \$8.4B-t az Animation-ben, Columbia Pictures \$10B-t az Action-ben**. A Profit Breakdown by Genre area chart mutatja, hogy a **profit folyamatosan növekedett az 1920-as évektől**, különösen meredek emelkedés látható a 2000-es évektől. A **Top 10 Highest ROI filmek** (Love 911, Between

Us, Kiss of the Spider Woman, stb.) jellemzően **kis költségvetésű független vagy horror filmek**, amelyek kimagasló megtérülést értek el. A **Bottom 10 Lowest ROI filmek** (The 312, Gold, Delgo, A Family On Edge, stb.) jellemzően **nagy költségvetésű bukások**, amelyek nem találták meg a közönségüket. Az **ROI Distribution histogram** mutatja, hogy a **legtöbb film 0-10x ROI tartományban** van, csak kevés film éri el a 50x+ ROI-t.

Fő felismerések: A legtöbb film mérsékelt profitot ér el (0-3x ROI), amely stabil, de nem kiemelkedő megtérülést jelent. A **legnagyobb nyereségű filmek franchise-ok** (Marvel, Pixar), amelyek ismétlődő bevételi forrást jelentenek. A **legnagyobb veszteségek high-budget filmek**, amelyek alulteljesítettek (Delgo, A Family On Edge). A **stúdiók specializálódnak: Marvel az Action-ben, Pixar az Animation-ben**, míg a **nagy stúdiók (Wamer Bros, Universal) diverszifikáltak** több műfajban. Az **átlagos profit margin 64.49%**, amely egészséges profitabilitást jelez az iparágban.

4. ML Predictions Dashboard - Gépi tanulási előrejelzések

Ez a dashboard a Linear Regression modell eredményeit vizualizálja. A három KPI kártya mutatja: **Model Accuracy (R^2): 0.7005** (amely meghaladja a specifikációban előírt 0.6-os küszöböt), **Mean Absolute Error (MAE): \$38.44M** (a modell átlagosan ± 38.44 millió dollárral tér el a valós bevételtől), és **11 ezer total predictions** (előrejelzés a teljes test set-re).

Az **Actual vs Predicted Revenue scatter plot** mutatja, hogy a modell előrejelzései mennyire közelítik a valós bevételeket - a **zöld pontok (over-performing filmek)** a **trendline felett**, a **piros pontok (under-performing filmek)** a **trendline alatt** helyezkednek el. A legtöbb pont közel van a diagonális trendline-hoz, ami jó modell fit-et jelez.

A **Top 10 Over-Performing Films** táblázat kiemeli azokat a filmeket, amelyek **jelentősen jobban teljesítettek** az előrejelzésnél: **Avatar (\$2.92B actual vs \$1.16B predicted, +\$1.76B error)**, **Avatar: The Way of Water (\$2.32B vs \$1.10B, +\$1.22B)**, **Avengers: Endgame (\$2.80B vs \$1.23B, +\$1.57B)**, **Barbie (\$1.45B vs \$481M, +\$965M)**. Ezek jellemzően **blockbuster franchise filmek**, amelyek viral marketing, word-of-mouth és brand értékük miatt meghaladják a költségvetés-alapú előrejelzéseket.

A **Top 10 Under-Performing Films** táblázat kiemeli azokat a filmeket, amelyek **rosszabbul teljesítettek**: **DeAD (\$201M actual vs \$942M predicted, -\$740M error)**, **Fight Club (\$101M vs \$824M, -\$724M)**, **Interstellar (\$702M vs \$1.16B, -\$461M)**, **Pulp Fiction (\$214M vs \$675M, -\$461M)**. Ezek gyakran **kultikus vagy art house filmek**, amelyek kisebb közönséget céloznak meg, vagy nem találták meg a mainstream piacot a kiadáskor.

A **Prediction Performance Distribution** bar chart mutatja, hogy **~6 ezer film over-performed** (zöld), míg **~2 ezer film under-performed** (piros). Ez azt jelenti, hogy a modell **konzervatív előrejelzéseket** ad, gyakrabban alulbecsülve a filmek bevételét.

Fő felismerések: A modell **70.05%-os pontossággal ($R^2=0.7005$)** jósolja a bevételeket, amely megbízható üzleti döntéshozatalhoz. Az **átlagos hiba \$38.44M**, amely elfogadható margin a film ipar volatilitását figyelembe véve. A **budget a legerősebb prediktor** - magasabb budget általában magasabb bevételt eredményez. Azonban vannak kivételek: **blockbuster franchise filmek gyakran felülteljesítenek** (Avatar, Avengers, Barbie), mivel a brand érték, marketing és word-of-mouth hatások nehezen modellezhetők. **Art house és kultikus filmek gyakran alulteljesítenek** (Fight Club, Pulp Fiction, The Shawshank Redemption), mivel kisebb niche közönséget céloznak meg. A modell **konzervatív**, hiszen több film teljesít jobban mint várva (6e vs 2e), amely biztonságos megközelítés a befektetési döntéseknél.

MACHINE LEARNING MODEL

Linear Regression - Revenue Prediction

Features (bemeneti változók):

- **Budget (numeric)** - A film költségvetése dollárban, amely a legerősebb prediktor a bevétel előrejelzésében. Standardizálva van 0 átlag és 1 szórásra a jobb modell teljesítményért.
- **Genre (one-hot encoded)** - A műfaj kategórikus változó, amely 19 dummy változóra lett széttranszformálva (is_Action, is_Horror, stb.). Például egy Action film esetén is_Action=1, összes többi műfaj=0.
- **Release Month (categorical)** - A megjelenési hónap (1-12), amely szezonálisitást rögzít - például a nyári hónapok (június-augusztus) magasabb bevétellel járnak.
- **Studio (one-hot encoded)** - A stúdió neve one-hot encoding-gal kódolva, amely rögzíti a nagy stúdiók brand értékét (pl. Disney filmek várhatóan magasabb bevételt érnek el).

Model Performance (teljesítmény metrikák):

- **R² Score: 0.7005** - A modell a bevétel varianciájának 70%-át magyarázza, amely meghaladja a specifikációban előírt 0.6-os küszöböt. Ez azt jelenti, hogy a modell megbízhatóan előre tudja jelezni a legtöbb film bevételét.
- **Mean Absolute Error (MAE): \$38.44M** - A modell átlagosan ±38.44 millió dollárral tér el a valós bevételtől.
- **Train/Test Split: 80/20** - A teljes adathalmaz 80%-át használtuk a modell tanítására (8,667 film) és 20%-át tesztelésre (2,167 film), amely biztosítja hogy a modell nem overfitted.
- **Cross-Validation: 5-fold** - Az adathalmazt 5 részre osztottuk és 5-ször tanítottuk a modellt, minden alkalommal más részt hagyva ki validációra. Ez biztosítja a robusztus teljesítmény becslést.
- **Mean CV Score: 0.68** - Az 5 cross-validation fold átlagos R² értéke 0.68, amely konzisztens a test score-al (0.70), tehát a modell nem overfitted.

Predictions (előrejelzések):

- **Output:** revenue_predictions.csv - A modell kimenete egy CSV fájl, amely minden test filmre (11,000 film) tartalmazza az actual és predicted bevételt.
- **Columns:** actual_revenue (valós bevétel), predicted_revenue (előrejelzett bevétel), error (eltérés a kettő között), film_title (film címe az azonosításhoz).
- **Power BI import successful** - A CSV sikeresen importálva lett a Power BI-ba, amely lehetővé teszi az interaktív vizualizációt és performance analysis-t.

Key Insights from ML (főbb felismerések):

- **Budget → Revenue correlation: 0.75** - Erős pozitív korreláció a költségvetés és bevétel között, amely azt mutatja hogy a magasabb költségvetés általában magasabb bevételt eredményez, de nem garantáltan.
- **Top predictive features: Budget, Genre (Action/Adventure)** - A modell feature importance analízise szerint a budget a legerősebb prediktor, majd az Action/Adventure műfaj, amely szignifikánsan növeli a várható bevételt.
- **Over-performing films: Blockbuster franchises** - Avatar (+\$1.76B), Avengers: Endgame (+\$1.57B), Barbie (+\$965M) jelentősen meghaladták a költségvetés-alapú előrejelzéseket a brand érték és viral marketing miatt.
- **Under-performing films: Art house/kultikus filmek** - Fight Club (-\$724M), Pulp Fiction (-\$461M), The Shawshank Redemption (-\$582M) kisebb közönséget céloztak meg, mint a mainstream blockbusterek.
- **Konzervatív modell:** ~6000 film over-performed vs ~2000 under-performed, amely azt mutatja hogy a modell biztonságos (alulbecsüli a bevételeket), amely jó befektetési döntéshozatalhoz.

Data Model: A Power BI data modellje a Data Warehouse star sémáját tükrözi, DirectQuery módban az SQL Database felé a valós idejű adatokért, és Import módban az aggregált táblák esetén a gyorsabb betöltésért. A DAX mértékek kiszámítják a komplex metrikákat: Total Revenue összegzi a fact tábla összes bevételét, Avg ROI átlagolja a megtérülési rátákat, Profit Margin kiszámítja a profit és bevétel arányát százalékban. Ezek a mértékek dinamikusan újraszámolódnak amikor a felhasználó szűrőket alkalmaz.

Összegzés

A Movie Analytics Platform egy production-ready üzleti intelligencia rendszer, amely modern cloud-native megközelítést alkalmaz. A rendszer valós üzleti értéket teremt a filmipar számára, prediktív modellezéssel és interaktív dashboardokkal támogatva a döntéshozatalt. A projekt során azonosított üzleti insights (műfaji trendek, költségvetés-bevétel összefüggés, stúdió teljesítmény) konkrét stratégiai döntéseket támogatnak: mely műfajokba érdemes befektetni, mekkora költségvetéssel maximalizálható az ROI, mely stúdiókkal érdemes partnerséget kötni. GitHub Repository: [RabaTamas/MovieAnalyticsPlatform](https://github.com/RabaTamas/MovieAnalyticsPlatform)